

面向版本化规范文档的本体语义漂移证据约束修复方法

匿名作者

Abstract

版本化规范文档，例如技术标准、监管指南和协议规范，会持续修订定义、义务、例外、适用范围和生效条件。这类变化会使基于旧版本规范构建的OWL 本体产生语义漂移：本体在语法上仍然有效，但其断言已经不再被当前规范证据支持。直接让大语言模型选择修复候选虽然实现简单，但难以审计，且容易受到候选描述、候选顺序、候选编号或隐含答案信息的影响。为解决这一问题，本文将本体语义漂移修复建模为一个证据约束的候选选择与形式化验证问题。

本文提出一种证据约束的语义中间表示本体修复方法。该方法首先基于公开规范证据进行谓词感知的证据聚焦，然后根据公开的semantic type 与predicate 将事件路由到时间版本、一般规则-例外、跨句作用域等任务表述；随后抽取原子事实，并转化为类型化语义中间表示；在语义结果固定后，系统才读取有限修复候选，并通过约束感知排序和选择性安全门控决定是否执行修复。被接受的修复还必须完成OWL patch 物化、Reasoner 一致性检查、RDF 图差分验证和competency question 回归验证。

在冻结M16 方法后新构建的RFC 真实规范文档blind-large benchmark 上，本文方法在264 个事件、每个事件5 次运行、共1320 次调用中取得1319/1320 的OWL 修复闭环成功率，即99.92%，Wilson 95% 置信区间为99.57%–99.99%；严格事件成功率为263/264，即99.62%，Wilson 95% 置信区间为97.89%–99.93%。消融实验显示，完整M16 方法相对M13 基础方法提升22.50 个百分点，配对McNemar 精确检验 $p = 7.85 \times 10^{-90}$ ，配对bootstrap 95% 置信区间为20.30–24.77 个百分点。候选note 隔离审计、V4.3 离线排序replay、DeepSeek/Ollama 后端替换、领域与来源族分组分析进一步表明，该方法不是依赖候选描述泄漏、固定编号或单一模型后端取得结果。

1 引言

本体常用于表示标准规范、监管规则、协议约束和领域知识。当其知识来源是规范文档时，本体的正确性不仅取决于逻辑一致性，还取决于其是否仍然被当前版本的规范证据支持。现实中，规范文档会不断更新：新版本可能替代旧版本，例外条款可能覆盖一般规则，限定语可能改变多个句子的作用域，或者某个属性值可能因为修订而失效。这些变化会导致本体出现语义漂移。

语义漂移不同于普通语法错误。本体可能仍然可以被reasoner 正常加载，也没有明显的逻辑不一致，但其中某个属性值、规则约束或适用范围已经不再符合当前规范。对于这类问题，只做文本差异比较不够，只做OWL consistency checking 也不够。系统需要理解规范文本中的版本关系、例外结构、作用域关系，并把这种理解转化为可验证的本体修复操作。

大语言模型为规范文本理解提供了新的可能，但直接使用LLM 也带来风险。模型可能输出格式正确但语义失真的JSON；可能因为候选描述写得更清楚而选择某个候选；可能受到候选顺序或编号的影响；也可能在证据不足时仍然给出确定修复。因此，本文不把问题简化为“让LLM 直接选择答案”，而是将其拆解为证据理解、语义中间表示、候选映射、选择性门控和形式化验证等多个可审计阶段。

本文研究问题可以表述为：

如何将版本化规范文档中的公开证据转化为可审计、候选隔离、可形式验证的OWL 本体修复决策？

本文主要贡献如下：

- 提出面向版本化规范文档的本体语义漂移修复问题定义，将修复任务建模为证据约束的有限候选选择与OWL 闭环验证问题。
- 设计证据约束的语义中间表示修复框架，包含谓词感知证据聚焦、任务表述路由、原子事实抽取、Semantic IR、约束感知候选排序、选择性安全门控、OWL patch、Reasoner 和CQ 回归验证。
- 在方法冻结后构建并冻结一个更大规模RFC 真实规范文档blind-large benchmark，覆盖264 个事件、11 个领域、13 个实际入选RFC 来源族和三类语义漂移类型；构建阶段的候选来源注册表包含69 条公开来源记录。
- 通过验证实验、消融实验、统计显著性检验、候选鲁棒性、模型后端对比、领域/来源族分组分析和失败分析，系统验证方法有效性与边界。

2 相关工作

2.1 本体演化与本体修复

本体演化研究关注知识库随领域变化而变化时如何保持一致性、可维护性和语义正确性。OWL 本体可以通过reasoner 检查逻辑一致性，但逻辑一致并不意味着语义仍然符合最新规范。已有本体修复研究多关注不一致公理删除、冲突定位和ontology alignment repair。本文关注的问题不同：源本体未必不一致，但其断言相对于版本化规范文档已经过时。因此，本文同时要求候选选择正确、OWL 修改成功、reasoner 一致，并通过competency question 回归验证修复闭环。

2.2 RAG 与证据选择

检索增强生成通常通过外部证据约束模型回答。近期研究指出，仅按相关性排序证据并不总是足够，因为最相关的片段未必最适合生成器进行推理。BAR-RAG 将reranker 重新理解为边界感知证据选择器，强调选择对生成器“足够、可解、不过度泄漏”的证据。本文的谓词感知证据聚焦可以看作这一思想在规范文档本体修复任务中的领域化实现：系统不直接把全文交给模型，而是围绕subject、predicate 和case context 裁剪证据窗口。

2.3 法律与监管信息抽取

法律和监管文本中的信息抽取长期被认为具有挑战性，因为文本包含定义、义务、例外、条件、优先级和跨句作用域。Legal IE 相关综述指出，法律文本中的实体、关系和事件抽取仍然面临结构复杂、语言多样和跨句推理困难等问题。De Jure 等监管规则抽取工作尝试将原始监管文本转化为结构化rule set，并使用LLM judge 和迭代修复提高质量。法律需求翻译研究也使用canonical representation 或executable code 表示法律文本。本文与这些工作类似，都强调规范文本结构化；不同之处在于，本文的最终目标不是单独抽取规则，而是完成OWL 修复候选选择和形式化闭环验证。

2.4 选择性预测与可信修复

在高风险任务中，不确定时拒绝预测是一种合理机制。选择性预测研究关注模型在低置信度情况下abstain，从而控制覆盖率与风险之间的权衡。本文将这一思想引入本体修复：只有当证据、Semantic IR、候选排序和OWL 验证都满足约束时，系统才执行patch；否则fail-closed，避免错误修复污染本体。

3 问题定义

给定版本化规范文档集合 D 、可能发生语义漂移的源本体 O_0 ，以及一个修复事件 E 。每个事件包含公开元数据，包括subject、predicate、semantic type、case context 和证据来源。对于每个事件，系统给定一个有限候选集合：

$$C_E = \{c_1, c_2, \dots, c_k\}.$$

每个候选包含display value 和形式化OWL 编辑操作。私有oracle 候选 c_E^* 只在离线评价阶段读取，不能进入模型输入、候选排序之前的语义抽取阶段或人工提示。

方法输出可以是某个候选 $\hat{c}_E$ ，也可以是abstain。若选择候选，则只有同时满足以下条件才记为修复闭环成功：

1. 选择候选与私有oracle 一致；
2. 候选OWL patch 成功物化；
3. 修复后本体通过reasoner 一致性检查；
4. RDF 图差分反映了预期编辑；
5. competency question 回归验证通过；
6. 修复满足最小修改约束。

本文报告三类指标：

- 调用级closure accuracy: 每次运行是否完成完整修复闭环；
- oracle selection accuracy: 每次运行是否选择oracle candidate；
- strict event success: 同一事件5 次运行是否全部闭环成功。

4 方法

4.1 总体框架

当前完整方法记为M16，由四个层次组成：

$$\text{Evidence} \rightarrow \text{Semantic IR} \rightarrow \text{Candidate Decision} \rightarrow \text{OWL Closure}.$$

具体流程如下：

阶段	作用
谓词感知证据聚焦	根据subject、predicate 和case context 裁剪公开证据
任务表述路由	将事件路由到时间版本、规则例外或作用域任务
原子事实抽取	从聚焦证据中抽取evidence-grounded facts
Semantic IR	将事实转化为类型化中间语义表示
约束感知排序	根据语义类型和本体约束给候选打分
选择性门控	证据和候选不充分一致时拒绝修复
OWL patch	将候选操作物化为OWL/RDF 修改
Reasoner + CQ	检查一致性和competency question 回归

4.2 三类语义漂移

本文考虑三类版本化规范文档中常见的语义漂移。

TEMPORAL_VERSION 表示版本、生效日期、替代关系或当前有效状态变化。其Semantic IR 包含subject、old value、new value、effective time、relation、current value 和evidence 等字段。

GENERAL_RULE_EXCEPTION 表示一般规则被例外、条件或优先级覆盖。其Semantic IR 包含subject、general rule、exception condition、exception rule、priority、result 和evidence 等字段。

CROSS_SENTENCE_SCOPE 表示限定语或作用域跨句附着，影响某个声明或多个声明。其Semantic IR 包含subject、statement、qualifier、scope target、scope relation、result 和evidence 等字段。

4.3 候选隔离

候选隔离是本文实验设计的关键。证据聚焦、规则抽取、语义中间表示构建等阶段只能读取公开证据、事件元数据、文档和检索信息，不能读取候选display value、候选operation、私有oracle 或人工formal policy。只有当semantic result 已经固定后，候选才进入ranking 阶段。这样可以避免模型从候选值反向猜测答案。

4.4 选择性修复门控

选择性门控的目标不是尽可能多地修复，而是在证据不足或候选不确定时拒绝修复。若Semantic IR 不完整、JSON 无效、候选得分过低或候选间无法区分，系统fail-closed。若候选被选中，还必须通过OWL materialization、reasoner consistency、RDF graph delta 和CQ regression。这个设计使系统能够把错误选择风险控制在形式化验证链路内。

5 Benchmark 构建

5.1 数据集概况

最终主实验使用external-real-holdout-v5-blind-large。该benchmark 是在M16 方法冻结后重新构建的独立blind-large 数据集，基于公开RFC 规范文档构建，包含264 个事件，每个事件运行5 次，共1320 次调用。数据覆盖11 个domain、13 个实际入选RFC source family 和三类semantic type；构建阶段的候选来源注册表包含69 条公开来源记录。此前的external-real-holdout-v1-expanded、external-real-holdout-v3-large 和external-real-holdout-v4-blind 用于早期诊断、方法开发、校准或验证；它们不作为本文最终主结果的数据集。

5.2 冻结与复核协议

方法冻结manifest 的SHA-256 为e27619e2...5def068，明确记录M16 的固定模块、阈值、输入隔离规则和禁止调参策略。随后构建external-real-holdout-v5-blind-large，完成264 个事件的oracle/support 复核、candidate notes 清洗、结构校验、深度质量审计和正式freeze。benchmark freeze manifest 的SHA-256 为40fcc2c3...9bb0e038。candidate notes 清洗只修改notes 字段，不修改candidate id、display value、operation 或oracle；冻结方法文件不读取candidate notes。

6 实验设置

6.1 比较方法

本文采用阶段式消融：

Table 1: 最终blind-large benchmark 概况

属性	数值
事件数	264
每事件运行次数	5
总调用次数	1320
Domain 数	11
实际入选source family 数	13
候选来源注册表规模	69
Semantic type 数	3
候选行数	792
清洗后candidate-note 泄漏行数	0
Benchmark manifest SHA-256	40fcc2c3...9bb0e038

Table 2: Full M16 在最终blind-large benchmark 上的结果

语义类型	Closure	Oracle	Strict event
ALL	1319/1320 (99.92%)	1319/1320 (99.92%)	263/264 (99.62%)
TEMPORAL_VERSION	440/440 (100.00%)	440/440 (100.00%)	88/88 (100.00%)
GENERAL_RULE_EXCEPTION	439/440 (99.77%)	439/440 (99.77%)	87/88 (98.86%)
CROSS_SENTENCE_SCOPE	440/440 (100.00%)	440/440 (100.00%)	88/88 (100.00%)

- **M13 Base:** 包含谓词感知证据聚焦、规则refinement、Semantic IR 和V4.3 修复决策。
- **M13+M14:** 加入GRE/CSS recovery。
- **M13+M14+M15:** 加入temporal anchor recovery。
- **Full M16:** 加入candidate entailment verifier。

6.2 评价指标与统计方法

主要指标包括closure accuracy、oracle accuracy 和strict event accuracy。比例指标使用Wilson 95% 置信区间。阶段对比使用matched event-run pairs 上的paired exact McNemar test, 并使用10000 次paired bootstrap 估计差值置信区间。

7 实验结果

7.1 主实验结果

结果显示, Full M16 在最终blind-large benchmark 上达到99.92% closure accuracy 和99.62% strict event success。TEMPORAL 和CSS 两类全部闭环成功, GRE 只剩1 次调用失败。该结果是在M16 方法冻结和v5 benchmark freeze 后取得, 因此可作为本文主盲测结果。

7.2 消融实验

消融结果说明每个模块均有明确贡献。M14 主要提升GRE/CSS 的失败子集; M15 解决v5 上最明显的TEMPORAL anchor 问题, 是最大增益来源; M16 进一步修复最后的GRE candidate entailment 边界案例。

Table 3: 阶段式消融实验

方法阶段	Closure	Strict event	相对M13 提升	阶段增益
M13 Base	1022/1320 (77.42%)	195/264 (73.86%)	0.00 pp	—
M13+M14	1058/1320 (80.15%)	205/264 (77.65%)	2.73 pp	2.73 pp
M13+M14+M15	1305/1320 (98.86%)	261/264 (98.86%)	21.44 pp	18.71 pp
Full M16	1319/1320 (99.92%)	263/264 (99.62%)	22.50 pp	1.06 pp

Table 4: 全量候选选择baseline 与Full M16 对比

方法	输入/模块	成功率	
OPTION_VALUE_ONLY	evidence + candidate value	1234/1320 (93.48%)	最强
OPTION_FORMAL_OPERATION	evidence + formal operation	1171/1320 (88.71%)	operation 易
Full M16	evidence-constrained repair closure	1319/1320 (99.92%)	完整

7.3 候选选择Baseline

为检验最终结果是否仅来自候选集合本身过于明显，本文补充两个全量候选选择baseline。二者均读取公开evidence、事件元数据和候选集合，但不执行本文的Semantic IR 分层修复、选择性门控、OWL patch、reasoner 和CQ closure。OPTION_VALUE_ONLY 只向模型提供候选display value；OPTION_FORMAL_OPERATION 提供候选display value 和形式化operation object。

结果表明，v5 benchmark 并非只靠候选值即可自然达到接近满分。Full M16 比最简单baseline OPTION_VALUE_ONLY 高6.44 个百分点，并且Full M16 的指标是完整closure，而baseline 只评价candidate selection。

7.4 统计显著性与置信区间

Full M16 相比M13 Base 的提升达到22.50 个百分点，且统计显著。所有阶段增益的bootstrap 95% 置信区间均不跨0。

7.5 鲁棒性实验

为检验候选顺序和候选编号是否驱动结果，本文在v5 benchmark 上构建两个派生扰动副本：candidate-order-shuffle 只打乱每个事件的候选行顺序，candidate-id-rename 将候选编号一致替换为中性ALT_A/ALT_B/ALT_C 并同步重写private Oracle。原始benchmark 不被修改。在线子集实验使用前30 个事件、每个事件5 次运行，即每个扰动150 次调用，并运行完整M13–M16 管道。为检验候选顺序和候选编号是否驱动结果，本文在v5 benchmark 上构建两个派生扰动副本：candidate-order-shuffle 只打乱每个事件的候选行顺序，candidate-id-rename 将候选编号一致替换为中性ALT_A/ALT_B/ALT_C 并同步重写private Oracle。原始benchmark 不被修改。在线鲁棒性实验覆盖全部264 个事件、每个事件5 次运行，即每个扰动1320 次调用，并运行完整M13–M16 管道。

结果显示，候选顺序扰动下closure 仍为98.00%，候选编号重命名下closure 为95.33%。因此，方法并非简单依赖候选文件原始顺序或固定CAND_002 编号；但candidate-id rename 不是完全无影响，尤其对涉及LLM verifier 的GRE/CSS 边界样本仍有轻微下降。作为补充，本文还对v5 主结果中M13/V4.3 score-based ranking 层进行离线replay，具有candidate score 记录的1101 行中，candidate id rename 后top candidate 映射保持不变；另有219 行不适用。candidate notes 泄漏审计显示，清洗后792 行候选notes 中泄漏行数为0，且冻结方法文件没有读取candidate notes。结果显示，候选顺序扰动下closure 仍为99.77%，候选编号重命名下closure 为99.47%。因此，方法并非简单依赖候选文件原始顺序或固定CAND_002 编号；但扰动结果并非完全不变，剩余失败集中在GRE/CSS 的fail-closed 或abstain 边界案例。作为补充，本文还对v5 主结果中M13/V4.3 score-based ranking 层进行离线replay，具有candidate

Table 5: Full M16 Wilson 95% 置信区间

语义类型	指标	估计值	Wilson 95% CI
ALL	Attempt closure	99.92%	99.57–99.99%
ALL	Strict event closure	99.62%	97.89–99.93%
TEMPORAL_VERSION	Attempt closure	100.00%	99.13–100.00%
TEMPORAL_VERSION	Strict event closure	100.00%	95.82–100.00%
GENERAL_RULE_EXCEPTION	Attempt closure	99.77%	98.72–99.96%
GENERAL_RULE_EXCEPTION	Strict event closure	98.86%	93.84–99.80%
CROSS_SENTENCE_SCOPE	Attempt closure	100.00%	99.13–100.00%
CROSS_SENTENCE_SCOPE	Strict event closure	100.00%	95.82–100.00%

Table 6: 阶段增益的配对统计检验

对比	平均提升	Bootstrap 95% CI	McNemar p
Full M16 vs M13	22.50 pp	20.30–24.77 pp	7.85×10^{-90}
M13+M14 vs M13	2.73 pp	1.89–3.64 pp	2.91×10^{-11}
M13+M14+M15 vs M13+M14	18.71 pp	16.59–20.76 pp	8.84×10^{-75}
Full M16 vs M13+M14+M15	1.06 pp	0.53–1.67 pp	1.22×10^{-4}

score 记录的1101 行中，candidate id rename 后top candidate 映射保持不变；另有219 行不适用。candidate notes 泄漏审计显示，清洗后792 行候选notes 中泄漏行数为0，且冻结方法文件没有读取candidate notes。

7.6 泛化实验

Domain 级别上，11 个领域中有10 个达到100% closure，唯一非满分领域为dns_security，达到119/120，即99.17%。Source-family 级别上，13 个实际入选RFC 来源族中有12 个达到100%，唯一非满分来源族为IETF RFC 4035，达到119/120，即99.17%。

需要强调的是，该实验应表述为frozen-method domain/source-family test-slice evaluation，而不是训练式leave-one-domain-out learning experiment。因为本文方法没有针对每个domain 重新训练模型。

7.7 模型后端对比

作为补充后端鲁棒性实验，本文在external-real-holdout-v3-large 上比较了DeepSeek 云端模型和Ollama 本地qwen3.5:9b。该实验与上文264 事件的external-real-holdout-v5-blind-large 主结果属于不同实验版本，不能混作同一主结果。结果显示：

- Ollama closure: 1085/1100, 98.64%;
- DeepSeek closure: 1091/1100, 99.18%;
- 两者strict event 均为217/220。

这说明方法并非完全依赖某个云端大模型。两个后端在attempt 级别存在少量差异，但strict event 级别表现相同。

Table 7: v5 在线候选扰动鲁棒性子集实验

Table 8: v5 全量在线候选扰动鲁棒性实验

实验条件	Closure	Strict event
原始v5 前30 事件	149/150 (99.33%)	29/30 (96.67%)
candidate-order-shuffle	147/150 (98.00%)	28/30 (93.33%)
candidate-id-rename	143/150 (95.33%)	28/30 (93.33%)
原始v5	1319/1320 (99.92%)	263/264 (99.62%)
candidate-order-shuffle	1317/1320 (99.77%)	261/264 (98.86%)
candidate-id-rename	1313/1320 (99.47%)	261/264 (98.86%)

Table 9: 冻结方法的领域分组结果

Domain	Events	Closure	Strict event
dns_security	24	119/120 (99.17%)	23/24 (95.83%)
email_authentication	24	120/120 (100.00%)	24/24 (100.00%)
http_messaging	24	120/120 (100.00%)	24/24 (100.00%)
http_semantics	24	120/120 (100.00%)	24/24 (100.00%)
internationalized_identifiers	24	120/120 (100.00%)	24/24 (100.00%)
json_formats	24	120/120 (100.00%)	24/24 (100.00%)
oauth_authorization	24	120/120 (100.00%)	24/24 (100.00%)
privacy_considerations	24	120/120 (100.00%)	24/24 (100.00%)
security_considerations	24	120/120 (100.00%)	24/24 (100.00%)
tls_security	24	120/120 (100.00%)	24/24 (100.00%)
uri_templates	24	120/120 (100.00%)	24/24 (100.00%)

7.8 失败案例分析

最终v5 blind-large 实验中只剩1 次失败，来自事件H5_E017 的第5 次运行。该事件属于GENERAL RULE EXCEPTION，失败表现为M16 candidate entailment verifier 未找到唯一被证据支持的候选，因此选择abstain。

因此，最终错误不是JSON 格式问题，也不是TEMPORAL 或CSS 的系统性失败，而是一个窄范围的GRE 证据蕴含判别边界案例。该失败以abstain 结束，没有产生错误OWL patch。

因此，最终错误不是JSON 格式问题，也不是TEMPORAL 的系统性失败，而是GRE/CSS 边界样本中的证据蕴含或候选区分不确定性。所有剩余失败均以abstain 或fail-closed 结束，没有产生错误OWL patch。

8 讨论

实验表明，本任务的关键不是简单保证LLM 输出JSON 格式正确。早期实验已经发现，强制结构化输出虽然可以提高parse rate，但可能导致语义失真。本文最终方法通过拆分evidence focus、task formulation、Semantic IR、candidate-blind normalization、candidate-aware ranking 和formal closure，使得每个失败都可以定位到具体模块。

从消融结果看，M14、M15 和M16 分别解决不同类型的瓶颈。M14 对GRE/CSS 边界问题有效，M15 对v5 中暴露出的temporal anchor 问题提升最大，M16 进一步通过entailment verifier 修复最后一批候选语义判别问题。最终剩余失败为单次GRE abstain，说明系统性瓶颈已经基本被消除。

由于最终closure accuracy 达到99.92%，本文必须主动排除“benchmark 过易”或“候选泄漏”的解释。首先，主结果不是在方法开发用的v1/v3/v4 数据集上取得，而是在M16 方法冻结

Table 10: 最终主实验与全量扰动实验的剩余失败

实验	主要事件	失败调用	解释
原始Full M16	H5_E017	1	GRE tie-abstain
candidate-order-shuffle	H5_E003/H5_E207/H5_E257	3	GRE/CSS fail-closed 或abstain
candidate-id-rename	H5_E003/H5_E017/H5_E137	7	GRE/CSS fail-closed 或abstain

后重新构建、复核并freeze 的v5 blind-large 数据集上取得。其次，candidate notes 在公开发布前被统一清洗，冻结方法不读取notes 字段；Oracle 位于private 路径，只在预测固定后用于计分。再次，M13 Base 只有77.42% closure，说明仅依靠公开证据和基础Semantic IR 并不能自然达到接近满分；M14-M16 的逐步提升来自明确的新增机制，而不是简单任务本身。最后，唯一剩余错误以abstain 结束，说明safety gate 仍保持fail-closed，而不是为了追求准确率强行选择候选。

9 有效性威胁

来源领域限制。 最终benchmark 主要来自RFC/IETF 风格的公开技术规范。虽然覆盖11个domain 和13 个实际入选RFC 来源族，但不能直接推出对所有法律、监管或行业规范文本都有效。本文结论应限定为版本化技术规范文档中的证据约束OWL 修复；迁移到法规、合同、临床指南等更强语境依赖的文本时，需要重新构建domain vocabulary、candidate generation protocol 和独立hold-out。

数据构造限制。 v5 benchmark 使用真实公开RFC 文档和原始evidence window，但repair event、subject/predicate metadata 与候选集合仍由实验协议构造。因此本文验证的是已知潜在漂移事件条件下的证据约束修复，而不是从完整文档库中自动发现全部漂移事件。若要主张完整semantic drift detection，还需要另行补充discovery-level precision、recall 和F1 实验。

schema 依赖。 方法使用semantic type、任务表述路由和领域级规范词汇，因此不能声称是完全自动的开放域规则学习系统。

oracle 复核限制。 当前benchmark 使用单人复核。虽然已有evidence window、freeze manifest 和private oracle isolation，但未来仍应增加多标注者一致性分析。

领域分组表述边界。 当前domain/source-family 实验是冻结方法后的测试切片分析，不是每个domain 重新训练后的transfer learning 实验。

candidate notes 泄漏处理。 早期候选notes 含有oracle 暗示文本。该问题已通过post-sanitize 清洗修复，审计显示泄漏行为0，且离线scoring 证明清洗不改变最终结果。论文和公开材料必须只使用清洗后的benchmark manifest。

最终盲测边界。 本文将早期v1/v3/v4 数据集定位为诊断、校准或验证数据。最终主结果使用M16 冻结后重新构建并freeze 的v5 blind-large benchmark。后续若继续修改方法，必须再构建新的独立数据集，不能继续把v5 作为最终盲测。

10 结论

本文提出一种面向版本化规范文档的证据约束语义中间表示本体修复方法。该方法将LLM 的规范文本理解能力与候选隔离、约束感知排序、选择性安全门控和OWL 形式化验证结合起来。在264 个真实RFC 事件、1320 次调用的最终blind-large 实验中，Full M16 达到99.92% closure accuracy 和99.62% strict event success。消融、统计检验、鲁棒性、领域分组和失败分析共同表明，该方法能够稳定地将版本化规范证据转化为可审计的OWL 修复决策。